

BOOTCAMP DE IA • PUCP
EJE FINANZAS Y GOBERNABILIDAD

EL SOL QUE MÁS RINDE

Estimación del retorno marginal del gasto público contra la anemia infantil mediante visión por computadora satelital, grafos de ejecución presupuestal e inferencia causal

Reporte Técnico — Reestructuración sobre datos reales del pipeline (panel_distrital_final.csv)

ODS 2 (Hambre Cero) — principal • ODS 1, 3 y 10 — secundarios

Versión de trabajo — 13 de agosto de 2026

Índice

1. Resumen ejecutivo
2. Introducción y contexto: por qué finanzas y gobernabilidad
3. Estado del arte y justificación
4. Armado de datos (actualizado) — el data warehouse real del proyecto
5. Análisis exploratorio de datos (actualizado) — la historia que cuentan los datos
6. Variable objetivo (target) definitiva
7. Modelamiento
8. El plus de IA avanzada: Graph ML sobre la red de ejecución del gasto
9. La aplicación — entregable público
10. Responsabilidad y límites declarados
11. Conclusión e impacto medible
12. Próximos pasos viables para terminar el campamento
13. Anexo — diccionario de datos completo

1. Resumen ejecutivo

El Perú gasta miles de millones de soles al año en programas contra la anemia infantil sin saber, distrito por distrito, dónde ese gasto realmente reduce la anemia y dónde se diluye sin efecto. Este proyecto ya dejó de ser una propuesta conceptual: existe hoy un pipeline de datos verificado en disco — data/clean/merged/panel_distrital_final.csv, 13,148 filas × 36 columnas, grano distrito (ubigeo) × año, cobertura 2020-2026, 1,891 ubigeos únicos, 0 duplicados en la clave — construido a partir de ocho fuentes públicas ya procesadas (geobase, SRTM, JRC, ESA WorldCover, Google Open Buildings, RENAMU, SIEN/REUNIS y SIAF).

Este documento reescribe el plan de trabajo con base en esa data real: define la variable objetivo con precisión (prevalencia_anemia, $\text{ninos_con_anemia} / \text{ninos_evaluados}$, con su sesgo de selección documentado), diseña tres modelos de creciente sofisticación (XGBoost/LightGBM como piso predictivo, SHAP como capa de interpretabilidad, y Causal Forest + Double ML como el diferenciador, con tratamiento, resultado y confusores especificados sobre columnas reales del panel), y agrega el componente de IA avanzada que el proyecto todavía no tenía: Graph ML sobre la red unidad-ejecutora-distrito-programa que ya está latente en los datos de SIAF, para exponer un riesgo de gobernanza que hoy es invisible — qué unidades ejecutoras concentran gasto de distritos rurales dispersos, la causa raíz de por qué el ubigeo del gasto no siempre coincide con el distrito de intervención real.

Se incluyen, sin maquillaje, tres hallazgos críticos de validación descubiertos al auditar el archivo real: un bug de codificación que sesga dos variables de control municipal hacia "No" en años específicos, una columna "region" que no contiene costa/sierra/selva como promete la documentación, y dos distritos con gasto no marginal (uno de ellos con S/ 601 millones acumulados) que hoy pierden todo su contexto territorial en el merge. Corregir estos tres puntos es la primera tarea del plan de trabajo, antes de entrenar cualquier modelo.

2. Introducción y contexto: por qué finanzas y gobernabilidad

El eje de este proyecto no es salud pública por sí sola — es la decisión financiera y de gobernanza que determina si la salud pública funciona. El Estado peruano ejecuta gasto devengado en el Programa Articulado Nutricional (PAN, programa presupuestal 0001) y en programas complementarios (salud materno-neonatal, saneamiento rural, Cuna Más, Qali Warma, JUNTOS, incentivos municipales) de forma sostenida, y sin embargo la prevalencia de anemia en menores de 3 años sigue siendo alta en la sierra rural, con brechas persistentes entre distritos que reciben niveles de gasto per cápita similares.

Esto es, en esencia, un problema de finanzas públicas: no basta con medir cuánto se gastó (lo que ya hace el SIAF) — hace falta estimar cuánto rindió ese gasto, distrito por distrito, para poder reasignarlo. Y es un problema de gobernabilidad: el propio dato de ejecución (SIAF) identifica dónde está registrada la unidad ejecutora, no necesariamente dónde se presta el servicio — una limitación estructural del sistema de administración financiera del Estado que el proyecto convierte en una pregunta analítica en vez de ignorarla.

La urgencia es doble. Primero, cada año de retraso en identificar dónde el gasto rinde y dónde no, es un año adicional de daño cognitivo permanente en niños que la anemia severa temprana puede causar — el costo de la mala asignación no es solo fiscal. Segundo, el ciclo presupuestal peruano (formulación, programación multianual, ejecución, evaluación) ya tiene los mecanismos institucionales para reasignar gasto entre programas presupuestales; lo que falta no es un canal de política, es evidencia distrital creíble sobre dónde reasignar. Este proyecto construye esa evidencia.

3. Estado del arte y justificación

El poverty mapping satelital tiene literatura consolidada: Jean et al. (Science, 2016) predicen pobreza a partir de imágenes nocturnas y diurnas; el Relative Wealth Index de Meta hace lo mismo a escala global; Chi et al. (PNAS, 2022) refinan la predicción de pobreza con transferencia de aprendizaje. Todo ese trabajo responde la pregunta "¿qué tan pobre es este lugar?". Ninguno responde "¿cuánto rinde acá un sol adicional de gasto público en salud?" — que es una pregunta de efecto marginal condicionado al territorio, no de nivel.

El problema no es trivial por cuatro razones concretas, verificadas en los propios datos del proyecto:

- Endogeneidad del gasto: el Estado gasta más donde ya hay más necesidad. Cualquier regresión simple entre `gasto_total` y `prevalencia_anemia` en el panel actual arrojaría, con altísima probabilidad, una correlación positiva espuria (a mayor gasto, mayor anemia observada) — exactamente el patrón que el documento maestro anticipa y que solo un método de inferencia causal con residualización puede desenredar.
- El contexto territorial que modula ese efecto no existe en ninguna base administrativa: la dispersión de viviendas, el acceso a agua o la accesibilidad vial de un caserío rural solo se puede leer desde una imagen satelital, no desde un padrón.
- El join de fuentes es, en la práctica, el cuello de botella técnico más caro del proyecto: se requirieron nueve notebooks (00a a 00i) para llegar a un panel limpio, y la auditoría de esta sesión encontró tres problemas de calidad de datos que ningún merge automático detecta solo — hay que leer diccionarios oficiales (RENAMU, SIAF) columna por columna para no arrastrar errores de codificación al modelo.
- El sesgo de selección del registro administrativo de anemia (SIEN) es real y está documentado en el panel: refleja quién llegó a tamizarse, no la prevalencia real del distrito — corregirlo exige anclar en ENDES, un paso metodológico (estimación en áreas pequeñas) que todavía no se ha aplicado a los datos.

Nota: La respuesta preparada para el jurado ante "¿esto no es lo mismo que el paper de Stanford de 2016?" sigue vigente: la etapa de visión es infraestructura conocida, reutilizada deliberadamente porque está validada. La novedad — reforzada en este documento — está en la capa causal, en la capa de decisión presupuestal, y ahora también en la capa de grafo sobre la ejecución del gasto (sección 8), que ninguno de esos trabajos de poverty mapping contempla.

4. Armado de datos (actualizado) — el data warehouse real del proyecto

Esta sección reemplaza la tabla conceptual de fuentes del documento maestro original por la estructura real, verificada en disco, del repositorio causal-anemia-model. El pipeline sigue tres capas: data/raw/ (crudo, pesado, ignorado en git) → data/clean/staging/ (un archivo por fuente, versionado) → data/clean/merged/ (panel unido final, la tabla que alimenta todo el modelamiento).

4.1 Capa staging — ocho tablas fuente, una por dataset público

Archivo (staging)	Grano	Columnas clave	Cobertura real
geobase_distrital.gpkg	1 fila / distrito	UBIGEO, departamento, provincia, distrito, region, macroregion_inei, macroregion_minsa, capital, latitude, longitude, altitude, superficie, pob_densidad_2020, geometry	1,889 distritos (universo INEI 2025 CPV, 5 discrepancias excluidas)
srtm_distrital.csv	1 fila / distrito	ubigeo, elevacion_media, pendiente_media	1,889 distritos (SRTM 30m)
jrc_distrital.csv	1 fila / distrito	ubigeo, pct_agua_permanente, pct_agua_estacional	1,806/1,889 con dato directo; 83 imputados a 0 ("sin agua detectada")
open_buildings_distrital.csv	1 fila / distrito	ubigeo, n_edificios, area_construida_m2, confianza_media, area_distrito_km2, densidad_edificios_km2	1,889 distritos (Google Open Buildings V3)
esa_worldcover_distrital_2021.csv	1 fila / distrito	ubigeo, pct_cultivo, pct_construido, pct_desnudo, pct_agua_visible	1,889 distritos (ESA WorldCover 2021)
renamu_distrital_2021_2024.csv	distrito × año encuesta	ubigeo, Año, personal_total, programa_anemia, centro_salud_municipal	2021-2024 (módulo de anemia recién existe desde 2021)
sien_reunis_distrital_2020_2026.csv	distrito × año tamizaje	ubigeo, Año, ninos_evaluados, ninos_con_anemia, ninos_sin_anemia, prevalencia_anemia	2020-2026, shape (13,029, 9)
siaf_gasto_devengado_distrital_2021_2025.csv	distrito × año ejecución	ubigeo, ANO_EJE, gasto_total, gasto_anemia_pan	2021-2025, shape (9,452, filas)

4.2 Capa merge — panel_distrital_final.csv, la tabla maestra

Ruta: data/clean/merged/panel_distrital_final.csv · Grano: ubigeo × anio · Shape verificado: (13,148, 36) · Ubigeos únicos: 1,891 · Duplicados en la clave ubigeo+anio: 0.

Metodología de merge (notebook 02_anemia_and_spending_models/00a_mergue_database.ipynb): las 8 tablas de staging se cargan y normalizan primero (ubigeo forzado a string de 6 dígitos con cero a la izquierda — crítico porque varias tablas lo traían como int64, perdiendo el cero de los departamentos 01-09; columnas de año renombradas a anio). Se separan en tablas estáticas (geobase, esa_worldcover,

open_buildings, srtm, jrc — una fila por distrito, sin variación temporal) y tablas panel (renamu, siaf, sien_reunis — distrito × año). Las tres tablas panel se unen entre sí con merge "outer" sobre [ubigeo, anio] para no perder ningún año que una fuente cubra y otra no. El panel resultante se une luego a la base estática con left join sobre ubigeo, transmitiendo el contexto territorial a cada fila-año del distrito.

Riesgo crítico: El notebook de merge (00a_mergue_database.ipynb) está vacío en disco (0 bytes) pese a haber producido panel_distrital_final.csv en una sesión interactiva reciente. Es la tarea #1 de la sección 12 de este documento: si no se vuelve a guardar, el trabajo de esta etapa se pierde en el siguiente reinicio del entorno.

4.3 Bugs de pipeline ya corregidos (documentados en las bitácoras)

- Ruta relativa rota en todos los notebooks 00a-00h: corregida de forma sistemática con un bloque find_project_root() que sube desde el directorio de trabajo hasta encontrar requirements.txt, evitando el patrón frágil "../data/raw/..."
- programa_anemia mal mapeado a P68_7 ("control de ITS y VIH/SIDA") en vez de P68_10 ("prevención y reducción de la anemia") — corregido tras verificar el diccionario oficial RENAMU 2021 (Diccionario_Anexo01.pdf, Módulo V, pregunta 59). Sin esta corrección, el modelo habría usado una variable de control completamente distinta a la pretendida, sin ningún error visible en el código.
- Inconsistencia de mayúsculas en la columna Ubigeo del Excel crudo de SIEN (Trama_Base_Anemia.xlsx), que rompía el groupby por KeyError — corregida y renombrada a ubigeo minúscula para calzar con la convención del resto del proyecto.

4.4 Bugs de calidad de datos encontrados en esta auditoría — pendientes de corregir

#	Hallazgo	Severidad	Impacto en el panel
1	El marcador de Excel "#¡NULO!" se decodificó como 0 ("No") en vez de NaN, en programa_anemia (2023: 563 de 1,891 filas) y centro_salud_municipal (2022: 1,368 de 1,874 filas)	Crítico	73% de los distritos en 2022 y 30% en 2023 quedan marcados como "No" sin haber respondido — sesga sistemáticamente estas dos variables de control hacia "No" en esos años
2	La columna region no contiene costa/sierra/selva: es una copia literal de departamento (26 valores únicos, no 3 categorías naturales)	Importante	Cualquier modelo o gráfico que use region como proxy de macrorregión natural está usando, en realidad, el nombre del departamento
3	130112 (Alto Trujillo) y 180107 (San Antonio, Moquegua) pierden su departamento/provincia/distrito y todo el contexto territorial satelital en el merge final, pese a que 180107 acumula S/ 601 millones de gasto y 130112 S/ 33.4 millones — no son casos marginales como 160405 (excluido de SIAF, S/ 402 mil)	Importante	9 filas del panel quedan con todas las variables de contexto territorial en NaN, para un monto de gasto demasiado grande para excluir sin más

Confirmado como correcto en esta auditoría (sin hallazgos): el shape y los nulos por columna coinciden exactamente con el diccionario documentado; ubigeo es 100% de 6 dígitos con cero a la izquierda preservado; cero duplicados en ubigeo+anio; prevalencia_anemia siempre en [0,1]; ninos_evaluados = ninos_con_anemia + ninos_sin_anemia se cumple en el 100% de las filas no nulas; todas las variables

pct_* están dentro de [0,1]; gasto_total y gasto_anemia_pan nunca son negativos y gasto_anemia_pan nunca supera a gasto_total; los nombres de columna son idénticos entre staging y merge final.

5. Análisis exploratorio de datos (actualizado) — la historia que cuentan los datos

Es importante ser precisos sobre lo que ya existe: el EDA ejecutado hasta ahora es un EDA de validación de calidad — verifica shape, nulos, rangos e integridad referencial contra la documentación, no todavía un EDA de distribuciones y correlaciones sustantivas (histogramas de prevalencia por macrorregión, mapa de calor de correlaciones entre gasto/contexto territorial/anemia, dispersión gasto vs. anemia). Ese segundo EDA es la tarea inmediata siguiente (sección 12) — no se inventan aquí cifras de correlación que no están todavía calculadas sobre el archivo real.

Lo que el EDA de validación sí cuenta, con evidencia concreta:

- La cobertura temporal es asimétrica por diseño, no por accidente: el target (SIEN) cubre 2020-2026, el tratamiento (SIAF) cubre 2021-2025, y los controles (RENAMU) cubren 2021-2024. El modelo causal debe restringirse a la intersección real (2021-2024/2025), donde las tres piezas coexisten para el mismo distrito-año.
- Los patrones de nulos no son ruido aleatorio, tienen causa administrativa identificada: 3,696 nulos en gasto_total/gasto_anemia_pan son años (2020, 2026) fuera de la cobertura real de SIAF, no datos faltantes; 5,622-5,812 nulos en las variables RENAMU son la misma lógica para 2020/2025/2026; 9 nulos en todo el bloque de contexto territorial son exactamente los 2 ubigeos huérfanos del hallazgo 3 de la sección anterior.
- El diseño del fillna(0) para JRC (agua superficial) fue una decisión deliberada, no un descuido: los 83 distritos sin dato directo de JRC se codificaron como 0% de agua detectada, distinto de "sin dato" — una decisión de modelamiento del propio equipo, correctamente documentada.
- 15 distritos (mayoría zonas remotas de selva/sierra: Ahuayro, Putis, Unión Progreso, Kumpirushiatro, Cielo Punco, Manitea, Unión Asháninka) tienen coordenadas, superficie y densidad poblacional vacías desde el propio dato censal de origen — no es un error de conversión de tipos, se verificó explícitamente que la conversión texto→número no falló en ningún caso.

Pendiente honesto: Próximo paso concreto de EDA (no hecho todavía, no inventar el resultado): correlación de Pearson/Spearman entre prevalencia_anemia y cada variable de contexto territorial (pct_agua_permanente, densidad_edificios_km2, pendiente_media, altitud), separada por macrorregion_inci, más un scatter gasto_anemia_pan vs. prevalencia_anemia para visualizar en vivo la correlación positiva espuria que motiva el diseño causal de la sección 7.

6. Variable objetivo (target) definitiva

El proyecto usa dos definiciones de variable dependiente, coherentes entre sí pero adaptadas a la etapa del pipeline — no es ambigüedad, es una decisión de diseño explícita:

6.1 Target del Modelo 1 (predictivo, baseline) — prevalencia_anemia observada

prevalencia_anemia = $\text{ninios_con_anemia} / \text{ninios_evaluados}$, a nivel distrito $\times$ año, tal como se agrega directamente de SIEN/HIS-MINSA (Trama_Base_Anemia.xlsx), filtrado a menores de 3 años. Es la variable ya presente en el panel, con $13,148 - 161 = 12,987$ filas no nulas. Se usa como target del modelo predictivo clásico (sección 7.1) precisamente porque todavía no existe la versión corregida por sesgo de selección — usarla como está, documentando su limitación, es más honesto que fabricar una corrección que el pipeline no ha aplicado.

6.2 Target del Modelo 3 (causal) — el mismo prevalencia_anemia, con la limitación declarada como parte del resultado

Para el Causal Forest (sección 7.3) se usa la misma prevalencia_anemia observada como resultado (Y), pero el efecto marginal τ estimado se comunica explícitamente como estimado sobre el registro administrativo, no sobre la prevalencia real — hasta que la Etapa 5 del documento maestro (modelo bayesiano de dos cabezas anclado en ENDES) se implemente y produzca una prevalencia corregida. Esta es la misma honestidad metodológica que el documento maestro ya aplica a τ : se declara la limitación en vez de ocultarla.

6.3 Target alternativo evaluado y descartado por ahora

Se consideró usar `ninios_con_anemia` (conteo absoluto) como target, con `ninios_evaluados` como offset/exposure en un modelo Poisson o binomial — estadísticamente más apropiado para tasas con denominador variable que un continuo en $[0,1]$. Se deja documentado como mejora técnica del Modelo 1 (sección 7.1), no como cambio del target sustantivo: sigue siendo la misma cantidad, prevalencia de anemia, con distinta parametrización estadística.

7. Modelamiento

7.1 Modelo 1 — XGBoost / LightGBM (piso predictivo)

Objetivo: predecir `prevalencia_anemia` por distrito-año a partir del contexto territorial y de gestión, como piso de referencia — no es el diferenciador del proyecto, es la prueba de que las variables territoriales tienen poder predictivo real antes de pasar a la capa causal.

Features (columnas reales del panel):

- Territorial satelital: `pct_cultivo`, `pct_construido`, `pct_desnudo`, `pct_agua_visible`, `pct_agua_permanente`, `pct_agua_estacional`, `n_edificios`, `densidad_edificios_km2`, `area_construida_m2`, `elevacion_media`, `pendiente_media`, `altitud`, `superficie`, `pob_densidad_2020`.
- Gestión municipal (RENAMU, con corrección de desfase de año aplicada antes de entrenar): `personal_total`, `programa_anemia`, `centro_salud_municipal`.

- Gasto (SIAF): `gasto_total`, `gasto_anemia_pan` — incluidas como feature aquí, no como tratamiento; el Modelo 1 no busca causalidad, solo predicción.
- Geografía: `macroregion_inei` y `macroregion_minsa` como categóricas (no `region`, por el hallazgo 2 de la sección 4.4).

Justificación técnica:

XGBoost/LightGBM manejan nativamente los patrones de missingness ya documentados (splits que aprenden la dirección óptima para los NaN, sin necesidad de imputación arbitraria), capturan no linealidades e interacciones (ej. dispersión de viviendas × altitud) sin especificarlas a mano, y dan una importancia de variables inmediata como primer chequeo de si el contexto territorial aporta señal — el mismo espíritu de la sonda lineal de validación del embedding (etapa 4 del documento maestro), aplicado aquí sobre variables tabulares con nombre.

Validación:

K-fold espacial en bloques geográficos (agrupando por `macroregion_inei` o clusters de ubigeos vecinos), nunca K-fold aleatorio — la autocorrelación espacial haría que un fold aleatorio filtre información de distritos vecinos casi idénticos, inflando artificialmente el desempeño. Métrica principal: RMSE y MAE sobre `prevalencia_anemia`, comparado contra un baseline ingenuo (media de prevalencia por macrorregión) para que el R^2 se lea en contexto, no como número aislado.

7.2 Modelo 2 — SHAP sobre el Modelo 1 (interpretabilidad, complementario)

Se eligió interpretabilidad (SHAP TreeExplainer sobre el XGBoost del Modelo 1) en vez de una red neuronal o LSTM independiente, por una razón de honestidad con los datos disponibles: el panel no tiene todavía una serie temporal densa por distrito que justifique una arquitectura secuencial — la serie NDVI de Sentinel-2 (notebook `00d_ndvi_extraction.ipynb`) sigue en proceso y su CSV de salida (`sentinel2_ndvi_distrital_2021_2025.csv`) todavía no existe ni está incorporado al panel. Construir un LSTM sobre datos que no existen sería inventar, no modelar.

SHAP cumple además un rol de puente hacia la capa causal y hacia el asistente explicativo (etapa 9 del documento maestro): produce, por distrito, qué variables dominan la predicción del Modelo 1 (ej. "en este distrito, `densidad_edificios_km2` y `pct_agua_permanente` explican la mayor parte de la predicción"), que se comunica al jurado con la distinción explícita de que SHAP explica al modelo predictivo, no mide un efecto causal — esa distinción es exactamente el argumento que separa al Modelo 2 del Modelo 3.

Condición de activación: Extensión futura, condicionada: si `00d_ndvi_extraction.ipynb` termina de correr y el CSV de NDVI se incorpora al panel, un LSTM o un Temporal Fusion Transformer sobre la serie fenológica por distrito pasa a ser una mejora justificada del Modelo 2 — hoy no lo es, porque el dato no existe todavía en el panel.

7.3 Modelo 3 — Causal Forest + Double Machine Learning (el diferenciador)

Esta es la pieza que la idea original no podía desarrollar sin datos y que hoy sí se puede especificar con columnas reales del panel.

Elemento causal	Definición operacional (columna real)
Tratamiento (T)	gasto_anemia_pan del año, idealmente normalizado como $\text{gasto_anemia_pan} / \text{ninios_evaluados}$ (aproximación per cápita disponible hoy en el propio panel, sin esperar el Padrón Nominal de REUNIS); gasto_total como especificación de robustez alternativa
Resultado (Y)	prevalencia_anemia del mismo distrito-año ($\text{ninios_con_anemia} / \text{ninios_evaluados}$), con la limitación de sesgo de selección declarada en la sección 6.2
Confusores / covariables (X)	Todo el contexto territorial satelital (pct_cultivo , pct_construido , pct_desnudo , $\text{pct_agua_visible/permanente/estacional}$, n_edificios , $\text{densidad_edificios_km2}$, $\text{area_construida_m2}$, elevacion_media , pendiente_media , altitute , superficie , pob_densidad_2020) + controles de gestión municipal RENAMU (personal_total , programa_anemia , $\text{centro_salud_municipal}$, con el desfase de año corregido) + macroregion_inei como control geográfico fijo
Unidad de análisis / panel	ubigeo $\times$ año, restringido a la intersección real de cobertura de T, Y y X (aprox. 2021-2024)

Estrategia de identificación:

Double Machine Learning en dos pasos: (1) un modelo de machine learning (ej. LightGBM) predice el tratamiento T desde las covariables X, se conserva el residuo; (2) otro modelo predice el resultado Y desde las mismas covariables X, se conserva el residuo. Sobre esos dos residuos, un Causal Forest con honest splitting (Athey & Wager) estima el efecto heterogéneo $\tau(x)$ en cada región del espacio de covariables, sin necesidad de especificar a mano interacciones como "sierra rural $\times$ agua insegura $\times$ viviendas dispersas".

Sin una fuente de variación exógena confirmada, τ se reporta como índice de priorización basado en heterogeneidad estimada, no como efecto causal probado — la misma decisión de honestidad metodológica que ya declaraba el documento maestro. Se explora el canon minero como candidato a instrumento (shocks de precios internacionales de minerales $\rightarrow$ canon $\rightarrow$ presupuesto municipal, estrategia ya usada en la literatura peruana), pendiente de verificar la restricción de exclusión antes de comprometerse con ella.

Ventaja adicional que el panel real permite y que la idea original no podía anticipar: al tener grano distrito $\times$ año con cobertura de tratamiento en 2021-2025, se puede especificar un diseño de efectos fijos por distrito dentro del DML, controlando por confusores time-invariant no observados (ej. cultura de gestión municipal persistente) que ninguna variable satelital captura — un refuerzo de identificación disponible solo porque el panel tiene dimensión temporal real, no solo corte transversal.

8. El plus de IA avanzada: Graph ML sobre la red de ejecución del gasto

Se revisaron las seis bitácoras y el panel completo buscando texto libre, relaciones entre entidades, o imágenes adicionales a las ya centrales en el pipeline (satelitales). El resultado honesto: no hay texto libre en ninguna de las fuentes ya procesadas (RENAMU es categórico/numérico, SIAF es tabular puro,

SIEN es agregado numérico) — por lo que un pipeline de NLP no tiene día 0. Lo que sí existe, sin explotar todavía, es una red de relaciones latente en la propia estructura del SIAF.

8.1 Por qué Graph ML y no NLP como componente obligatorio

La limitación estructural más citada en las bitácoras — "el ubigeo de SIAF identifica dónde está registrada la unidad ejecutora, no necesariamente el distrito donde se presta el servicio" — es, leída con otros ojos, una descripción de grafo: nodos de tipo unidad ejecutora, nodos de tipo distrito, nodos de tipo programa presupuestal, y aristas ponderadas por monto_devengado_anual. Esa estructura ya está en las columnas DEPARTAMENTO_EJECUTORA / PROVINCIA_EJECUTORA / DISTRITO_EJECUTORA y PROGRAMA_PPTO del SIAF crudo (notebook 00i) — no requiere ningún dato nuevo, solo una forma distinta de modelarlo.

8.2 Construcción del grafo

- Nodos: unidades ejecutoras (identificadas por su ubigeo de registro), distritos (ubigeo del panel), programas presupuestales (PROGRAMA_PPTO, con PAN 0001 como caso central).
- Aristas: unidad_ejecutora → distrito(s) que administra, ponderada por monto_devengado_anual; distrito → programa(s) ejecutado en él, ponderada por el mismo monto.
- Features de nodo iniciales: para cada unidad ejecutora, número de distritos distintos que administra y dispersión geográfica de esos distritos (distancia media entre ellos, usando latitude/longitude ya presentes en geobase_distrital.gpkg).

8.3 Qué se hace con el grafo

Dos aplicaciones concretas, ambas de gobernabilidad más que de predicción: (1) detección de comunidades (Louvain o similar) para encontrar unidades ejecutoras cuyo patrón de distritos administrados es anómalamente disperso — una señal directa de riesgo de que el gasto reportado no refleje bien la ejecución territorial real, exactamente el problema que hoy solo está declarado como limitación en texto; (2) opcionalmente, una Graph Neural Network (ej. GraphSAGE) que aprenda un embedding de cada distrito considerando no solo sus propias variables sino las de la unidad ejecutora que lo administra y los distritos "vecinos" en el grafo — ese embedding se puede añadir como covariable adicional X al Causal Forest de la sección 7.3, integrando grafo + visión + causal en un solo sistema, no dos capas independientes.

8.4 NLP — extensión futura, condicionada a datos que hoy no están en las carpetas

Se declara explícitamente: ningún archivo de las carpetas del proyecto trae texto libre hoy. La ruta realista de integración, si se decide perseguir NLP como segunda capa de "plus": el propio portal de Consulta Amigable/SEACE del MEF publica descripciones textuales de las metas presupuestales y memorias descriptivas de proyectos de inversión (ej. "Instalación del servicio de agua potable en el centro poblado X") — un campo de texto adicional del mismo SIAF que no se extrajo en el notebook 00i. Aplicar BERTopic o un clasificador simple sobre esas descripciones permitiría auditar si el gasto etiquetado bajo PAN (0001) corresponde realmente a una intervención de anemia/nutrición o es una

etiqueta administrativa genérica — una pregunta de gobernabilidad del gasto, coherente con el eje del proyecto. Esta vía queda documentada como extensión posible, no como parte del núcleo mínimo demostrable, porque requiere una nueva extracción de datos que aún no se ha hecho.

9. La aplicación — entregable público

Se mantiene el diseño ya validado del documento maestro (Streamlit, todo precalculado, sin inferencia en vivo el día de la presentación), actualizado con los nombres reales de archivo y una cuarta vista:

- Pantalla 1 — los tres mapas: Mapa A (prevalencia_anemia por distrito), Mapa B (τ del Causal Forest), Mapa C (reasignación presupuestal propuesta), todos generados desde `panel_distrital_final.csv` precalculado.
- Pantalla 2 — detalle por centro poblado: imagen satelital, segmentación, variables extraídas (`n_edificios`, `pct_cultivo`, dispersión), texto del asistente explicativo.
- Pantalla 3 — simulador contrafactual: interruptores sobre agua segura, vía de acceso y dispersión de viviendas, moviendo τ en vivo (sección 7.3).
- Pantalla 4 (nueva) — mapa de riesgo de gobernanza: visualización del grafo de la sección 8, resaltando las unidades ejecutoras con mayor dispersión territorial administrada — el hallazgo que convierte la limitación estructural del SIAF en un resultado presentable.
- Pantalla 5 — metodología y limitaciones: la tabla completa de la sección 10, sin editar para la presentación.

10. Responsabilidad y límites declarados

Toda salida del sistema es priorización y estimación, nunca una acusación a personas o autoridades específicas, y se reporta con incertidumbre explícita (intervalos de credibilidad, nunca valores puntuales). Las limitaciones verificadas sobre el panel actual, que deben trasladarse tal cual a la pantalla de metodología de la aplicación, son:

14. Sesgo de selección en anemia: el registro SIEN es administrativo (quién llegó a tamizarse), no un censo — pendiente de corrección con ENDES.
15. Gasto no normalizado por población infantil — soles absolutos, no per cápita, salvo la aproximación propuesta en la sección 7.3 (`gasto_anemia_pan / ninos_evaluados`).
16. El ubigeo de SIAF identifica la unidad ejecutora, no necesariamente el distrito de intervención real — la razón de ser del componente de grafo de la sección 8.
17. Desfase de año sin corregir en `personal_total/programa_anemia` (RENAMU) al momento de esta auditoría — corrección pendiente de aplicar antes del modelo causal.
18. 2 ubigeos (130112, 180107) sin contexto territorial en el panel pese a gasto no marginal — 9 filas afectadas.
19. 15 distritos con vacíos de origen en coordenadas/superficie/densidad — no es error del pipeline, es vacío del dato censal.

20. `gasto_anemia_pan` solo cubre PAN (0001), no los demás programas con incidencia en anemia que el propio documento maestro identifica (salud materno-neonatal, saneamiento rural, Cuna Más, Qali Warma, JUNTOS, incentivos municipales).
21. Sesgo de agregación ecológica: el contexto territorial describe el distrito completo; la anemia describe solo menores de 3 años — argumentado como tolerable a nivel de caserío rural, pero declarado explícitamente.
22. Solo 1,806 de 1,889 distritos tienen dato JRC directo de agua superficial; el resto se imputó a 0.
23. La columna `region` no distingue costa/sierra/selva — usar `macroregion_inei`/`macroregion_minsa` en su lugar hasta corregir la fuente.
24. El marcador "`#¡NULO!`" de Excel está mal decodificado como "No" en `programa_anemia` (2023) y `centro_salud_municipal` (2022) — no usar estas dos variables-año sin corregir primero.

11. Conclusión e impacto medible

El sistema, sobre datos reales ya integrados, permite dos tipos de impacto medible y comunicable ante un jurado técnico:

Impacto en salud/nutrición:

Con el mismo gasto total agregado nacional en PAN (calculable directamente como la suma de `gasto_anemia_pan` del panel), la optimización de reasignación (etapa 8 del documento maestro, todavía por ejecutar sobre τ del Modelo 3) produce una cifra concreta: cuántos casos de anemia se evitarían redistribuyendo el mismo presupuesto hacia los distritos con τ más alto, respetando la restricción de que ningún distrito pierda más de un porcentaje políticamente viable de su presupuesto actual. Esa cifra —no un mapa adicional— es el número central del pitch.

Impacto en gobernabilidad:

El componente de grafo (sección 8) produce un segundo número, igualmente concreto: cuántas unidades ejecutoras administran gasto de distritos con dispersión geográfica anómala, y cuántos distritos son "puntos ciegos" de datos (sin tamizaje suficiente para estimar su prevalencia con confianza) — dos indicadores de riesgo estructural del sistema de administración financiera del Estado que hoy no existen en ningún dashboard público.

Ambos números comparten la misma base de evidencia: un panel de datos ya auditado, con sus errores documentados y su plan de corrección explícito — la combinación que distingue a este proyecto de un dashboard de gasto o un mapa de pobreza más.

12. Próximos pasos viables para terminar el campamento

Lista priorizada, en el orden en que deben ejecutarse — cada paso depende de que el anterior esté resuelto:

25. Guardar 00a_mergue_database.ipynb — está vacío en disco pese a haber producido el panel final; es el riesgo más alto de perder trabajo ya hecho.
26. Corregir la decodificación de "#¡NULO!" → NaN en programa_anemia (2023) y centro_salud_municipal (2022), y revisar si el mismo marcador aparece con otro nombre en 2021/2024.
27. Aplicar la corrección de año retrospectivo de RENAMU (personal_total, programa_anemia → anio - 1) antes de cualquier entrenamiento causal.
28. Decidir el tratamiento de 130112 y 180107 (investigar si son distritos reorganizados después del corte del shapefile INEI 2025 y asignarles geometría manualmente, o excluirlos documentando el monto excluido, igual que se hizo con 160405 en SIAF).
29. Sustituir region por macroregion_innei/macrorregion_minsa en cualquier análisis o gráfico que necesite costa/sierra/selva, hasta corregir la fuente.
30. Ejecutar el EDA de distribuciones y correlaciones real (histogramas de prevalencia por macrorregión, mapa de calor de correlaciones, scatter gasto vs. anemia) — pendiente, no hecho todavía sobre el archivo actual.
31. Entrenar el Modelo 1 (XGBoost/LightGBM) con validación espacial en bloques geográficos.
32. Calcular SHAP sobre el Modelo 1 (Modelo 2) y verificar que las variables dominantes tengan sentido de dominio (agua, dispersión, altitud).
33. Implementar DML + Causal Forest (Modelo 3) con el desfase de RENAMU ya corregido y el tratamiento normalizado por ninos_evaluados.
34. Construir el grafo unidad-ejecutora-distrito-programa desde el SIAF crudo (00i) y correr detección de comunidades (Plus, sección 8).
35. Correr 00d_ndvi_extraction.ipynb hasta obtener el CSV final — solo entonces evaluar la extensión de serie temporal del Modelo 2.
36. Montar la aplicación Streamlit con las cinco pantallas de la sección 9, todo precalculado.
37. Grabar el video de respaldo de 90 segundos de la demo completa, por si falla el internet el día de la presentación.

Anexo — diccionario de datos completo (panel_distrital_final.csv)

Columna	Fuente	Definición	Nulos
ubigeo	Llave	Código INEI de distrito, 6 dígitos con cero a la izquierda	0
anio	Llave	Año de referencia (significado varía por bloque de variables)	0
ninos_evaluados	SIEN/REUNIS	Suma de niños <3 años tamizados en el distrito-año	119
ninos_con_anemia	SIEN/REUNIS	Suma de niños con resultado de anemia	119
ninos_sin_anemia	SIEN/REUNIS	Suma de niños con resultado normal	119
prevalencia_anemia	SIEN/REUNIS	ninos_con_anemia / ninos_evaluados	161

Columna	Fuente	Definición	Nulos
gasto_total	SIAF/MEF	Monto devengado anual, todos los programas presupuestales	3,696
gasto_anemia_pan	SIAF/MEF	Monto devengado anual, solo PAN (0001)	3,696
personal_total	RENAMU/INEI	Headcount total de personal municipal (P19D_T, retrospectivo)	5,812
programa_anemia	RENAMU/INEI	1=Si implementó programa de anemia con MINSA (P68_10, retrospectivo)	5,622
centro_salud_municipal	RENAMU/INEI	1=Si funciona centro de salud municipal (P66_2, no retrospectivo)	5,622
departamento/provincia/distrito	Geobase INEI/IGN	Nombres administrativos	9
region	Geobase INEI/IGN	Copia de departamento (no distingue costa/sierra/selva)	9
macroregion_inei / macroregion_minsa	Geobase INEI/IGN	Agrupación macro-regional (pueden diferir entre sí)	9
latitud / longitud / altitud	Geobase INEI/IGN	Coordenadas y altitud (ajusta el corte de hemoglobina)	97
superficie / pob_densidad_2020	Geobase INEI/IGN	Superficie (km²) y densidad poblacional 2020	125
pct_cultivo/construido/desnudo/agua_visible	ESA WorldCover 2021	% de cobertura de suelo por clase	9
n_edificios / area_construida_m2 / confianza_media / densidad_edificios_km2	Open Buildings V3	Proxy directo de dispersión de viviendas	9
elevacion_media / pendiente_media	SRTM 30m	Elevación y pendiente (proxy de accesibilidad)	9
pct_agua_permanente / pct_agua_estacional	JRC Global Surface Water	% de agua detectada; 83 distritos imputados a 0	9

Nota metodológica final: Este reporte se construyó exclusivamente a partir de los seis documentos y el PDF ya cargados en el proyecto (bitácoras 00a-00i, diccionario de datos y hallazgos de validación EDA). Ninguna cifra de este documento fue inventada; donde el dato no existía todavía (correlaciones, distribuciones), se declaró explícitamente como pendiente en vez de rellenarlo.